Analyse des comportements d'achat sur le dataset Black Friday avec Microsoft Azure

Matthieu PELINGRE

Master 2 Science des Données - M2SDD
Cours de Cloud Computing

Mars 2026

Dataset	Black Friday Sales (Kaggle, 550 068 transactions)
Services Azure	Blob Storage, Azure OpenAI, Text Analytics
Visualisation	Power BI

Introduction et architecture du pipeline

Ce projet s'inscrit dans le cadre du cours de Cloud du Master 2 Science des Données. L'objectif est de construire un pipeline complet, de la collecte jusqu'à la visualisation, en s'appuyant sur des services **Microsoft Azure**.

Le jeu de données choisi est le *Black Friday Sales Dataset*, disponible sur Kaggle, qui regroupe **550 068 transactions** effectuées lors d'un Black Friday par 5 891 clients distincts sur 3 631 produits. Le dataset étant purement transactionnel et encodé, une étape d'enrichissement par IA a été ajoutée pour tirer parti des services Azure d'intelligence artificielle.

Pipeline mis en uvre :

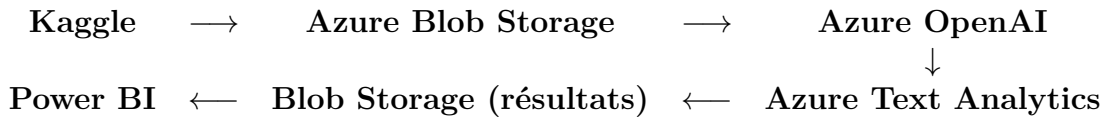

Exploration et ingestion des données

Description du dataset

Le dataset contient 12 variables :

Variable	Type	Description
`User_ID`	Catégoriel	Identifiant client
`Product_ID`	Catégoriel	Identifiant produit
`Gender`	Catégoriel	Sexe (F / M)
`Age`	Catégoriel	Tranche d'âge (7 modalités)
`Occupation`	Catégoriel encodé	Profession (21 codes anonymes)
`City_Category`	Catégoriel	Catégorie de ville (A, B, C)
`Stay_In_Current_City_Years`	Catégoriel	Ancienneté dans la ville
`Marital_Status`	Binaire	Statut marital
`Product_Category_1/2/3`	Catégoriel encodé	Catégories produit
`Purchase`	Numérique	Montant d'achat (devise non précisée)

Observation

La quasi-totalité des variables numériques sont en réalité des variables catégorielles encodées. De plus, la devise associée à `Purchase` n'est pas précisée dans le dataset, nous supposons qu'il s'agit de roupies indiennes (ce qui serait cohérent avec les montants observés et les données démographiques).

Valeurs manquantes et nettoyage

Les valeurs manquantes se concentrent sur les catégories secondaires et tertiaires des produits, qui sont optionnelles :

- `Product_Category_2` : 31,6 % de valeurs manquantes
- `Product_Category_3` : 69,7 % de valeurs manquantes

Ces valeurs ont été remplacées par `0` (catégorie inexistante), les catégories valides étant encodées entre 1 et 20.

Principales observations exploratoires

Quelques indicateurs clés issus de l'EDA :

- **75 % des transactions** sont effectuées par des hommes
- Le groupe d'âge le plus actif est **26–35 ans** (219 587 transactions, soit 40 % du total), cohérent avec une tranche à la fois plus nombreuse et à fort pouvoir d'achat
- Le **panier moyen** est de **9 264 unités monétaires** (médiane : 8 047), avec un écart-type de 5 023 révélant une forte disparité
- Les **catégories 5, 1 et 8** sont les plus achetées en volume, tandis que les **catégories 9, 10 et 16** affichent les montants moyens les plus élevés
- Les villes de **catégorie C** concentrent proportionnellement plus de gros montants que les catégories A et B

Observation

Le segment **Homme / 26–35 ans** domine si fortement (40 % des transactions) qu'il écrase les autres profils dans toutes les analyses par catégorie. Cette surreprésentation est à prendre en compte dans toute modélisation ou segmentation ultérieure.

Ingestion dans Azure Blob Storage

Après nettoyage et encodage des variables catégorielles, le fichier `blackfriday_clean.csv` (22,75 Mo, 550 068 lignes) a été téléversé dans un conteneur Azure Blob Storage privé.

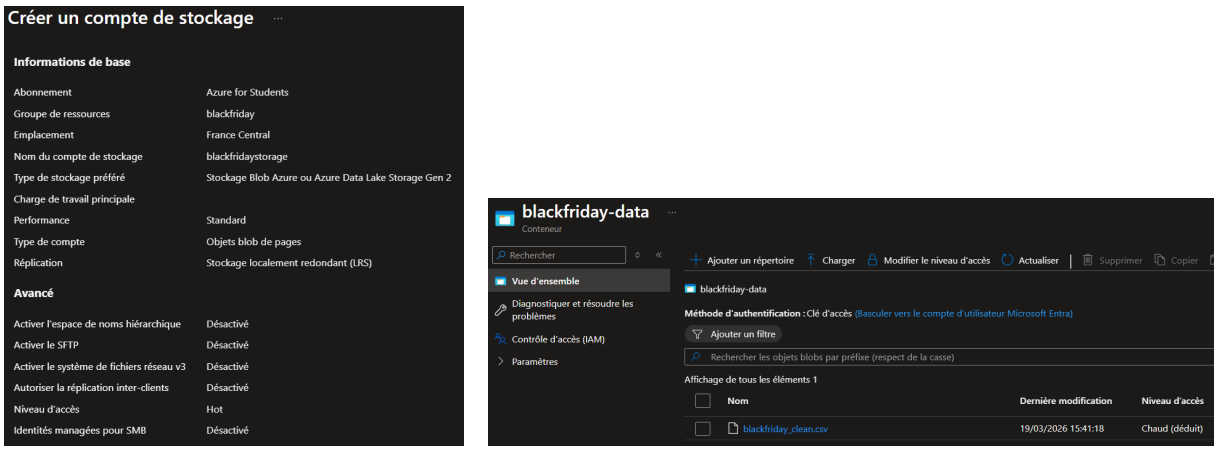

(a) Compte de stockage (b) Fichier téléversé dans le conteneur Blob

FIGURE 1 : Configuration Azure Blob Storage et téléversement du dataset

La configuration retenue est : compte de stockage *Standard*, redondance *LRS* (Locally Redundant Storage), niveau d'accès *Chaud (Hot)*. La vérification post-téléversement a confirmé l'intégrité du fichier (22,75 Mo, 550 068 lignes, 12 colonnes).

Enrichissement par les services IA d'Azure

Le dataset Black Friday étant purement transactionnel, il ne contient aucune donnée textuelle. Nous avons contourné cette limite en générant des **avis clients synthétiques** pour alimenter les services d'analyse d'Azure.

Segmentation et construction de personas (Azure OpenAI)

Pour limiter les coûts API, nous avons travaillé sur des **données agrégées** : 14 segments (croisement Sexe × Tranche d'âge) résumant l'ensemble du dataset. Pour chaque segment, le modèle **GPT-4o mini** (déployé via Azure AI Foundry) a généré :

1. Des **descriptions pour les 20 catégories de produits** anonymes (ex. : catégorie 1 = « Électronique de luxe », catégorie 8 = « Chaussures tendance »)
2. Des **personas marketing** pour chaque segment (profil fictif mais crédible)
3. Des **avis clients fictifs** (5 catégories × 3 niveaux de notation = 15 avis)

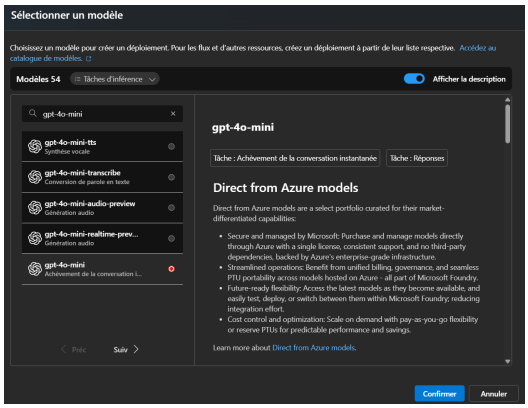

(a) Déploiement GPT-4o mini

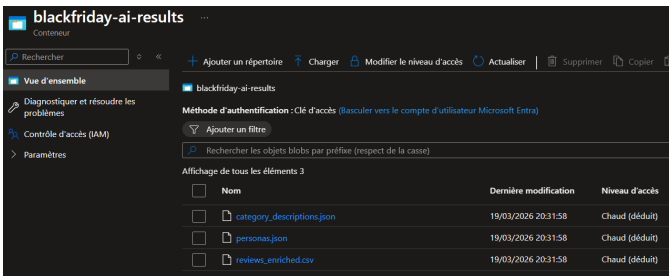

(b) Export des résultats vers Blob Storage

FIGURE 2 : Azure OpenAI : génération de contenu et export

Observation

Le persona dominant dans les avis est « Lucas, 30 ans » (segment H/26–35), reflet direct de la sur-représentation de ce groupe dans le dataset. La génération de personas par LLM constitue un **cas d'usage marketing classique** : enrichir une segmentation RFM (Récence, Fréquence, Montant) avec des profils narratifs directement actionnables par des équipes communication.

Analyse de sentiment et extraction de mots-clés (Azure Text Analytics)

Les 15 avis générés ont ensuite été soumis au service **Azure Language / Text Analytics** pour :

— **Analyse de sentiment** : classification positif / négatif / neutre avec score de confiance (13 analyses réussies sur 15, soit 87 %)

— **Extraction de mots-clés** (key phrases) : identification des thèmes récurrents par catégorie de produit

Exemples de mots-clés extraits par catégorie :

Catégorie	Mots-clés dominants
Électronique de luxe	luxe, appareil photo, smartphone, passionnés
Accessoires de mode	qualité, montre, élégante, compliments
Chaussures tendance	chaussures, confort, prix, journées
Articles de maison	qualité, décoration, produits, maison
Vêtements décontractés	tissu, t-shirt, collection, qualité

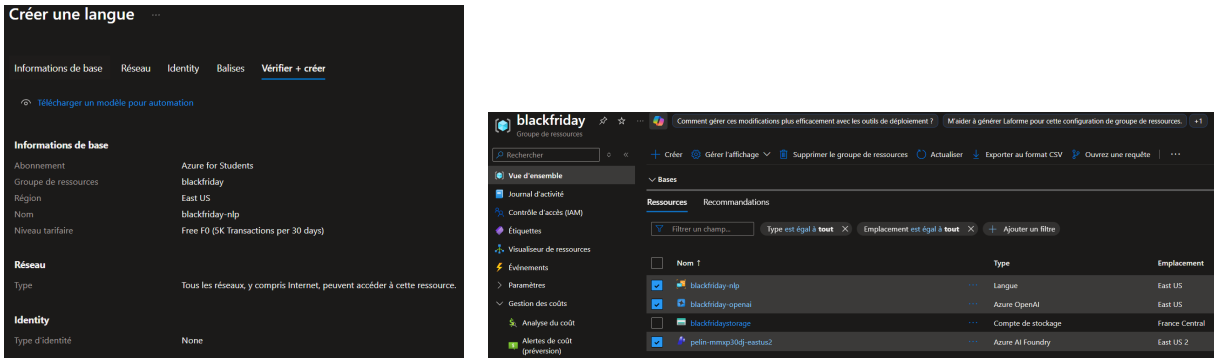

(a) Création du service Language (b) Vue d'ensemble du groupe de ressources

FIGURE 3 : Azure Text Analytics : configuration et résultats

Visualisation dans Power BI

Le dashboard Power BI est connecté directement à **Azure Blob Storage** (fichiers `blackfriday_clean.csv`, `reviews_enriched.csv` et `personas.json`) et structuré en trois pages.

FIGURE 4 : Page 1. Vue générale : achats par sexe, âge, catégorie de ville

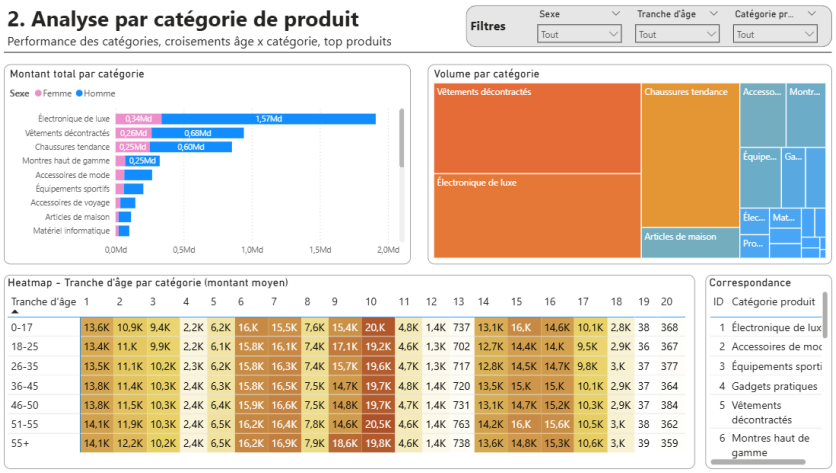

FIGURE 5 : Page 2. Analyse par catégorie de produits

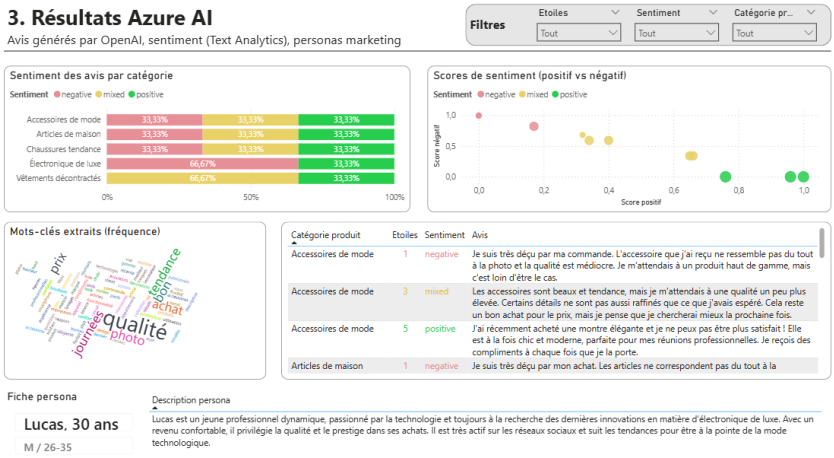

FIGURE 6 : Page 3. Insights IA : sentiments et mots-clés par catégorie

La connexion au Blob Storage permet une **mise à jour automatique** du rapport dès que les fichiers sources sont modifiés.

Observations, découvertes et applications futures

Ce que ce projet m'a appris

Sur Azure : La prise en main des services Azure est accessible : les API python sont simple d'utilisation et il semble assez aisé de transposer du code, créé pour fonctionner en local, vers le cloud. Toutefois, l'interface du **portail Azure** est peu intuitive et nécessite une attention particulière à la gestion des ressources et des coûts. Ce dernier point est d'ailleurs assez stressant. Mais, même en exécutant plusieurs requêtes API vers Azure OpenAI, pour un total de plusieurs milliers de tokens lors des tests, seul 0.01 € de crédit avait été consommé.

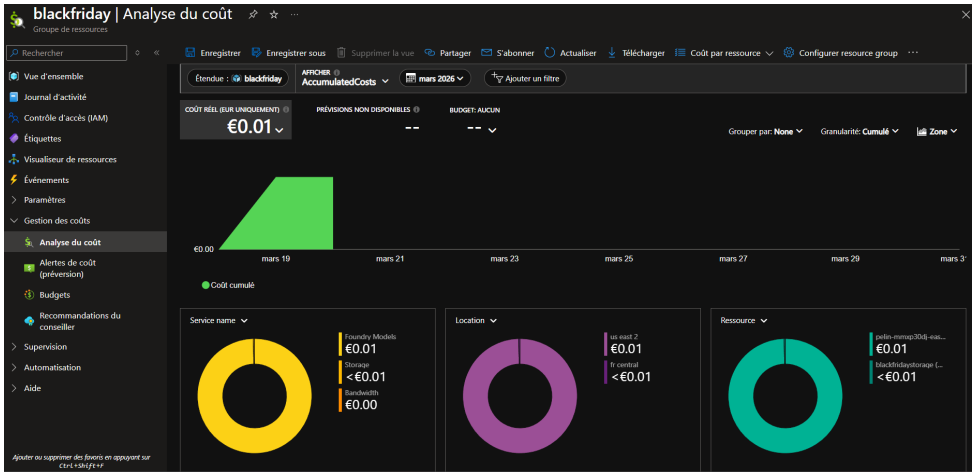

FIGURE 7 : Coûts générés par le groupe de ressources à l'issue du projet.

Sur le coût des API : Travailler sur des données agrégées (14 segments) plutôt que sur les 550 068 lignes brutes a sans doute également permis de maîtriser les coûts, tout en obtenant des résultats pertinents. Cela pourrait être une bonne pratique à systématiser avant tout appel LLM en production.

Applications professionnelles et futures

Ce pipeline, même dans sa version simplifiée, préfigure des architectures utilisées en production dans de nombreux contextes :

E-commerce & retail : Un pipeline similaire (transactions → Blob → LLM → dashboard) permet de générer automatiquement des rapports de veille consommateur, d'alimenter des systèmes de recommandation ou de détecter des tendances d'achat en temps quasi-réel.

Marketing data-driven : La génération de personas par LLM à partir de segments RFM est directement applicable : des équipes marketing peuvent disposer de profils narratifs actionnables sans expertise data avancée.

Analyse de l'e-réputation : L'analyse de sentiment via Azure Text Analytics est déployable à grande échelle sur de vrais avis clients (Amazon, Trustpilot, réseaux sociaux) pour monitorer la réputation d'une marque ou d'un produit en continu.

Extension vers du temps réel : En remplaçant le Blob Storage par **Azure Event Hubs** et le traitement batch par **Azure Stream Analytics**, ce pipeline pourrait être adapté à l'analyse de flux d'achats en temps réel (ex. : détection de pic de ventes, alertes fraude).

MLOps : Les données enrichies (sentiments, mots-clés, personas) constituent une base pour entraîner des modèles supervisés de recommandation ou de prédiction de churn, déployables via **Azure Machine Learning**.

D'un point de vue plus personnel, j'envisage d'utiliser Azure pour des petits projets personnels à très faible coûts (si ce n'est gratuit), mais je préfèrerai toujours travailler on-premise.

Bilan

Ce projet a permis de construire un pipeline cloud de bout en bout en mobilisant quatre services Azure complémentaires. Au-delà de la technique, il illustre comment des données brutes, sans valeur textuelle intrinsèque, peuvent être transformées en insights actionnables grâce à l'IA générative et à l'analyse de langue naturelle. Les architectures cloud modernes rendent ces traitements accessibles, scalables et économiquement maîtrisables, à condition de piloter rigoureusement les appels aux services afin de limiter les coûts.